ISCAE — Institut Supérieur de Commerce et d'Administration des Entreprises
Marrakech — Filière CAC 2 — Année 2025–2026

COMPTE RENDU DE PROJET

Intelligence Artificielle Appliquée à l'Audit

Audit Financier & Détection d'Anomalies

Classification des Risques d'Audit par Cycle Comptable

NOUBAIR Ziad

N° Étudiant : 22007685

IZLITNE Marouane

N° Étudiant : 22006529

Module	Intelligence Artificielle appliquée à l'Audit
Filière	CAC 2 — Commissariat aux Comptes (2ème année)
Outil	Python 3.10 — Google Colab
Référentiel	Normes ISA (IFAC) + Guides OECCA Maroc
Date	Marrakech, Mars 2026

TABLE DES MATIÈRES

1. **Contexte et Problématique**
   - 1.1 Contexte général
   - 1.2 Problématique
2. **Objectifs du Projet**
3. **Description des Données**
   - 3.1 Source et nature
   - 3.2 Structure du dataset
   - 3.3 Cycles comptables couverts
   - 3.4 Distribution de la variable cible
   - 3.5 Qualité des données
4. **Feature Engineering**
5. **Analyse Exploratoire des Données (EDA)**
6. **Préparation des Données pour la Modélisation**
7. **Modèles Testés**
8. **Résultats et Évaluation**
   - 8.1 Comparaison des modèles
   - 8.2 Modèle retenu
   - 8.3 Matrice de confusion
   - 8.4 Importance des features
9. **Cartographie des Risques et Planification**
   - 9.1 Matrice de risque

9.2 Programme de travail
9.3 Budget-temps estimé
9.4 Export des résultats

10. Discussion Critique

10.1 Apports du projet
10.2 Limites identifiées
10.3 Pistes d'amélioration

11. Conclusion

12. Références Normatives

1. CONTEXTE ET PROBLÉMATIQUE

1.1 Contexte général

La profession d'auditeur financier est au cœur d'une transformation numérique profonde. L'émergence de l'intelligence artificielle offre désormais la possibilité d'automatiser et de renforcer des processus jusqu'ici fondés exclusivement sur le jugement professionnel humain. Parmi ces processus, l'**évaluation et la classification des risques d'audit** constitue l'une des étapes les plus stratégiques de toute mission, conformément aux exigences de la norme **ISA 315**.

Au Maroc, le cadre normatif de l'audit est encadré par l'**OECCA** (Ordre des Experts Comptables et Comptables Agréés) qui a adopté les normes ISA dans leur version adaptée au contexte national, via le référentiel du **Plan Comptable Général Marocain (PCG Maroc)**. La mise en œuvre implique :

- L'identification systématique des risques par cycle comptable (ventes, achats, trésorerie, paie, etc.) ;
- Leur classification selon un niveau de criticité (faible, moyen, élevé) ;
- La conception de procédures d'audit adaptées au niveau de risque détecté.

1.2 Problématique

La réalisation manuelle de cette classification est chronophage, subjective et sujette à des biais humains. La question centrale de ce projet est la suivante :

> *Dans quelle mesure un modèle de machine learning peut-il automatiser la classification des risques d'audit par cycle comptable, en s'appuyant sur des données simulées conformes aux normes ISA et aux pratiques de l'OECCA Maroc ?*

2. OBJECTIFS DU PROJET

#	Objectif	Lien avec l'Audit
1	Construire une base de données simulée de risques par cycle comptable	ISA 315 — identification des risques
2	Réaliser un feature engineering sur des indicateurs financiers et comptables	ISA 315.25 — évaluation ordinale
3	Comparer plusieurs algorithmes de classification supervisée	ISA 330 — adaptation des procédures
4	Produire un programme de travail d'audit priorisé et exportable	ISA 300 — planification de la mission

3. DESCRIPTION DES DONNÉES

3.1 Source et nature

Le dataset utilisé est un **jeu de données simulé**, construit sur la base des référentiels ISA et des pratiques documentaires de l'OECCA Maroc. Il est stocké dans un fichier Excel (*base_donnees_risques_audit_cycle_comptable.xlsx*), feuille *Audit_Risks_DB*, et chargé via la bibliothèque **pandas** depuis Google Drive. Le recours à des données simulées est justifié par la confidentialité inhérente aux dossiers d'audit réels et par la nécessité de disposer d'un dataset équilibré et pédagogiquement représentatif.

3.2 Structure du dataset — 220 observations, 10 variables

Variable	Type	Description
ID	Texte	Identifiant unique du risque (R001 → R220)
Cycle comptable	Catégorielle	Cycle d'appartenance du risque (8 cycles)
Processus	Catégorielle	Sous-processus comptable concerné
Compte PCG Maroc	Texte	Numéro(s) de compte selon le PCG Maroc
Description du risque	Texte	Libellé descriptif du risque identifié
Type de risque	Catégorielle	Nature : Inhérent / Contrôle / Fraude
Assertion impactée	Catégorielle	Assertion d'audit concernée (6 modalités)
Niveau de risque	**Catégorielle (cible)**	**Faible / Moyen / Élevé**
Procédure d'audit	Texte	Type de procédure à mettre en œuvre
Documents de preuve	Texte	Pièces justificatives attendues

3.3 Cycles comptables couverts

Cycle comptable	Nb de risques	Part (%)
Ventes - Clients	30	13,6%
Achats - Fournisseurs	30	13,6%
Trésorerie	30	13,6%
Stocks	30	13,6%
Immobilisations	30	13,6%
Paie	30	13,6%
Fiscalité	30	13,6%
Capitaux propres	10	4,5%
TOTAL	**220**	**100%**

3.4 Distribution de la variable cible

Niveau de risque	Occurrences	Proportion
Faible	73	33,2%
Moyen	74	33,6%
Élevé	73	33,2%

Cet équilibre parfait entre les trois classes est un atout majeur pour la modélisation : il évite les biais de classe dominante et rend inutile le recours à des techniques de rééchantillonnage (SMOTE, undersampling, etc.).

4. FEATURE ENGINEERING

Le feature engineering est l'étape la plus critique du pipeline. Toutes les variables catégorielles ont été transformées en scores numériques ancrés dans la théorie de l'audit :

Feature créée	Logique de construction	Plage
type_risque_score	Inhérent=1 / Contrôle=2 / Fraude=3	1–3
assertion_score	Existence=1 → Exhaustivité=6	1–6
cycle_criticite	Score de criticité par cycle (1–5)	1–5
nb_comptes_pcg	Nombre de comptes PCG concernés	1–n
IRC (Indice Risque Combiné)	type × assertion × cycle	composé
priorite_audit	Score composite de planification	composé
Variables one-hot	Encodage cycles + assertions	0/1

5. ANALYSE EXPLORATOIRE DES DONNÉES (EDA)

L'analyse exploratoire a confirmé la cohérence interne du dataset simulé. Les principales observations sont les suivantes :

- Distribution parfaitement équilibrée de la variable cible (33% par classe) ;
- Absence totale de valeurs manquantes sur l'ensemble des 10 colonnes ;
- Corrélations fortes et attendues entre *type_risque_score*, *IRC* et le niveau de risque cible ;
- Représentation homogène des 8 cycles comptables (sauf Capitaux propres : 10 obs.) ;
- Visualisations produites : histogrammes, heatmaps de corrélation, boxplots par cycle.

6. PRÉPARATION DES DONNÉES POUR LA MODÉLISATION

La préparation suit un pipeline scikit-learn standard :

- **Séparation train/test** : 80% entraînement (176 obs.) / 20% test (44 obs.), stratifiée par classe ;
- **Encodage** : LabelEncoder sur la variable cible (Faible=0, Moyen=1, Élevé=2) ;
- **Normalisation** : StandardScaler sur les features numériques ;
- **Validation croisée** : 5-folds stratifiée pour l'évaluation des modèles.

7. MODÈLES TESTÉS

Cinq algorithmes de classification supervisée ont été implémentés et comparés :

Modèle	Abbrév.	Avantages clés
Régression Logistique	LR	Interprétabilité maximale, coefficients explicites
Arbre de Décision	DT	Règles lisibles, adapté aux auditeurs
Random Forest	RF	Robustesse, feature importance via Gini
Gradient Boosting	GB	Haute performance, gestion des interactions
K-Nearest Neighbors	KNN	Non-paramétrique, flexible

8. RÉSULTATS ET ÉVALUATION

8.1 Comparaison des modèles — Accuracy & F1-Score macro

Modèle	Accuracy Test	F1-Score Macro	CV Mean	CV Std
Régression Logistique ★	**100%**	**1.000**	**1.000**	**±0.000**
Arbre de Décision ★	**100%**	**1.000**	**1.000**	**±0.000**
Random Forest ★	**100%**	**1.000**	**1.000**	**±0.000**
Gradient Boosting ★	**100%**	**1.000**	**1.000**	**±0.000**
K-Nearest Neighbors	97.7%	0.977	0.994	±0.011

8.2 Modèle retenu

Le modèle retenu comme référence est la **Régression Logistique**, sélectionnée à iso-performance pour sa meilleure **interprétabilité** (coefficients lisibles) et sa conformité avec la logique de transparence requise dans les missions d'audit professionnelles.

8.4 Importance des features (Random Forest — critère Gini)

Rang	Feature	Interprétation audit
1	type_risque_score	Type Inhérent/Contrôle/Fraude — prédicteur dominant
2	IRC	Indice de risque combiné — feature synthétique
3	assertion_score	Criticité de l'assertion impactée
4	One-hot cycles	Cycles comptables spécifiques
5	priorite_audit	Score composite de planification

9. CARTOGRAPHIE DES RISQUES ET PLANIFICATION

9.2 Programme de travail d'audit — Procédures par niveau

Niveau	Procédure recommandée (ISA 330)	Budget
ÉLEVÉ	Tests substantifs étendus + Circularisation + Analyse comparative détaillée (ISA 330.18)	8h / risque
MOYEN	Tests de contrôle ciblés + Sondages sur pièces justificatives (ISA 330.8)	4h / risque
FAIBLE	Procédures analytiques + Revue des contrôles existants (ISA 330.4)	2h / risque

Budget global de la mission : **1 026 heures** sur **73 procédures** planifiées

10. DISCUSSION CRITIQUE

10.1 Apports du projet

- Construction d'un pipeline ML complet et reproductible (données brutes → export Excel) ;
- Création de features interprétables ancrées dans la normativité ISA ;
- Génération automatique d'un programme de travail conforme aux pratiques OECCA Maroc ;
- Démonstration de la capacité prédictive sur un nouveau risque non vu en temps réel.

10.2 Limites identifiées

Limite 1 — Données simulées
Le dataset est construit par règles déterministes, ce qui explique les performances parfaites. Sur des données réelles, les modèles devraient être réévalués avec plus de variabilité.

Limite 2 — Overfitting apparent
Les scores de 100% sont liés à la structure du dataset. La validation croisée confirme leur stabilité (std=0,000) mais ne garantit pas la généralisation hors-distribution.

Limite 3 — Déséquilibre des cycles
Le cycle Capitaux propres ne comprend que 10 observations contre 30 pour les autres cycles.

Limite 4 — Variables textuelles non exploitées
Les colonnes Description, Procédure et Documents de preuve sont des champs riches non valorisés (NLP à explorer).

10.3 Pistes d'amélioration

- **Données réelles** : intégration de données anonymisées issues de dossiers d'audit ;
- **NLP** sur les descriptions de risques (TF-IDF, embeddings) ;
- **XAI** : intégration de SHAP values pour justifier chaque prédiction ;
- **Déploiement Streamlit** : interface web pour classification instantanée en cabinet.

11. CONCLUSION

Ce projet a démontré comment les techniques d'intelligence artificielle — et plus particulièrement la classification supervisée — peuvent être mobilisées au service de l'audit financier pour **automatiser, standardiser et objectiver la classification des risques** par cycle comptable.

En s'appuyant sur une base de données simulée conforme aux normes ISA et au PCG Maroc, le projet a traversé l'ensemble des étapes d'un projet IA : exploration des données, feature engineering ancré dans la théorie de l'audit, comparaison de cinq algorithmes, évaluation par validation croisée, cartographie des risques et planification automatique des missions.

Résultat clé : 100% d'accuracy et F1-Score macro pour 4 modèles sur 5. Pipeline générant automatiquement un programme de travail de **1 026 heures** sur 73 procédures, directement exploitable par une équipe d'auditeurs.

12. RÉFÉRENCES NORMATIVES

Norme / Source	Titre	Application
ISA 200	Objectifs généraux de l'auditeur indépendant	Cadre conceptuel du risque
ISA 240	Responsabilités concernant les fraudes	Pondération risques de fraude (score=3)
ISA 300	Planification d'un audit d'états financiers	Budget-temps, programme de travail
ISA 315	Identification et évaluation des risques	Feature engineering, assertions, cartographie
ISA 330	Réponses aux risques évalués	Procédures recommandées par niveau
PCG Maroc	Plan Comptable Général Marocain — OECCA	Numérotation comptes (classes 3–7)
scikit-learn	Pedregosa et al. (2011) — JMLR	Framework ML : modèles, métriques
pandas / numpy	McKinney (2010) / Harris et al. (2020)	Manipulation et calcul données
matplotlib / seaborn	Hunter (2007) / Waskom (2021)	Visualisations et analyses graphiques

Compte rendu rédigé sur la base du notebook Projet_IA_CAC2_IZLITNE_MAROUANE_ET_NOUBAIR_ZIAD.ipynb

Marrakech, Mars 2026 — IZLITNE Marouane & NOUBAIR Ziad